

# 第六章 点估计(Point Estimation)

第一节 矩法估计

第二节 极大似然估计

第三节 克拉默-拉奥 (Cramer-Rao) 不等式

第四节 充分统计量

第五节 拉奥-勃拉克维 (Rao-Blackwell)

定理和一致最小方差无偏估计



# § 6.1 矩法估计

## Method of Moments Estimation



# 一、点估计问题的提法

设总体  $X$  的分布函数形式已知, 但它的一个或多个参数为未知, 借助于总体  $X$  的一个样本来估计总体未知参数的值的问题称为点估计问题.

**例6.1.1** 在某炸药制造厂, 一天中发生着火现象的次数  $X$  是一个随机变量, 假设它服从以  $\lambda > 0$  为参数的泊松分布, 参数  $\lambda$  为未知, 设有以下的样本值, 试估计参数  $\lambda$ .





着火次数 $k$	0	1	2	3	4	5	6	
发生 $k$ 次着 火的天数 $n_k$	75	90	54	22	6	2	1	$\Sigma = 250$

**解** 因  $X \sim P(\lambda)$ , 所以  $\lambda = E(X)$ .

用样本均值来估计总体的均值  $E(X)$ .

$$\bar{x} = \frac{\sum_{k=0}^6 kn_k}{\sum_{k=0}^6 n_k} = \frac{1}{250} (0 \times 75 + 1 \times 90 + 2 \times 54 + 3 \times 22 + 4 \times 6 + 5 \times 2 + 6 \times 1) = 1.22.$$

故  $E(X) = \lambda$  的估计为 1.22.



## 点估计问题的一般提法

设总体  $X$  的分布函数  $F(x; \theta)$  的形式为已知,  $\theta$  是待估参数.  $X_1, X_2, \dots, X_n$  是  $X$  的一个样本,  $x_1, x_2, \dots, x_n$  为相应的一个样本值.

点估计问题就是要构造一个适当的统计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$ , 用它的观察值  $\hat{\theta}(x_1, x_2, \dots, x_n)$  来估计未知参数  $\theta$ .

$\hat{\theta}(X_1, X_2, \dots, X_n)$  称为  $\theta$  的估计量. } 通称点估计,  
 $\hat{\theta}(x_1, x_2, \dots, x_n)$  称为  $\theta$  的估计值. } 简记为  $\hat{\theta}$ .



## 二、估计量的求法

常用构造估计量的方法: (两种)

**矩估计法和极大似然估计法.**





# 1. 矩估计法

## 基本概念

设  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本,  
若  $E(X^k)$ ,  $k = 1, 2, \dots$  存在,  
称它为总体  $X$  的  $k$  阶原点矩, 简称  $k$  阶矩.

样本  $k$  阶(原点)矩  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ,  $k = 1, 2, \dots$ ;

其观察值  $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k$ ,  $k = 1, 2, \dots$ .



**结论：** 若总体  $X$  的  $k$  阶矩  $E(X^k)$  记成  $\mu_k$  存在，

$$\text{则当 } n \rightarrow \infty \text{ 时, } A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, k = 1, 2, \dots.$$

**证明：** 因为  $X_1, X_2, \dots, X_n$  独立且与  $X$  同分布，

所以  $X_1^k, X_2^k, \dots, X_n^k$  独立且与  $X^k$  同分布，

故有  $E(X_1^k) = E(X_2^k) = \dots = E(X_n^k) = \mu_k$ 。

再根据第四章**辛钦大数定律**知





$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, \quad k = 1, 2, \dots;$$

由第四章关于依概率收敛的序列的性质知

$$g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k),$$

其中  $g(x_1, x_2, \dots, x_n)$  是有理函数, 且  $g(\mu_1, \mu_2, \dots, \mu_n) \neq \pm\infty$ .

这一结论是接下来所要介绍的矩估计法的理论根据.



设  $X$  为连续型随机变量, 其概率密度为  $f(x; \theta_1, \theta_2, \dots, \theta_k)$ , 或  $X$  为离散型随机变量, 其分布律为  $P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_k)$ , 其中  $\theta_1, \theta_2, \dots, \theta_k$  为待估参数,

若  $X_1, X_2, \dots, X_n$  为来自总体  $X$  的样本,

假设总体  $X$  的  $r$  阶原点矩存在,

且均为  $\theta_1, \theta_2, \dots, \theta_k$  的函数, 即

$$E(X^r) = \mu_r = \mu_r(\theta_1, \theta_2, \dots, \theta_k) \quad r = 1, 2, \dots, k$$



# 矩估计法思想:

用样本的 $r$ 阶原点矩  $A_r = \frac{1}{n} \sum_{i=1}^n X_i^r$  来估计总体的 $r$ 阶原点矩  $\mu_r = E(X^r), r = 1, 2, \dots, k$ .

具体做法: 考虑1~ $k$ 阶矩, 得方程组:

$$\text{令} \left\{ \begin{array}{l} E(X) = \frac{1}{n} \sum_{i=1}^n X_i \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 \\ \dots \\ E(X^k) = \frac{1}{n} \sum_{i=1}^n X_i^k \end{array} \right. \xrightarrow{\text{根据总体的分布计算总体的 } k \text{ 阶矩}} \left\{ \begin{array}{l} \mu_1(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i \\ \mu_2(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^2 \\ \dots \\ \mu_k(\theta_1, \theta_2, \dots, \theta_k) = \frac{1}{n} \sum_{i=1}^n X_i^k \end{array} \right.$$





这是一个包含 $k$ 个未知量  $\theta_1, \theta_2, \dots, \theta_k$  的方程组,

于是我们可以解方程,

用方程组的解  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  分别作为  $\theta_1, \theta_2, \dots, \theta_k$  的估计量, 这个估计量称为矩估计量.

矩估计量的观察值称为矩估计值.



**例6.1.2** 设总体  $X$  在  $[0, \theta]$  上服从均匀分布, 其中  $\theta$  ( $\theta > 0$ ) 未知,  $(X_1, X_2, \dots, X_n)$  是来自总体  $X$  的样本, 求  $\theta$  的矩估计量.

**解** 因  $E(X) = \frac{\theta}{2},$

根据矩估计法, 令  $E(X) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X},$  即  $\frac{\theta}{2} = \bar{X},$

解得  $\hat{\theta} = 2\bar{X}$  为所求  $\theta$  的矩估计量.



## 例6.1.3

$$r.v.X \sim f(x) = \begin{cases} (\theta+1)x^\theta & 0 < x < 1 \\ 0 & \text{其它} \end{cases}, \text{ 其中 } \theta > -1 \text{ 未知,}$$

求  $\theta$  的矩估计量。

**解**

$$\begin{aligned} E(X) &= \int_{-\infty}^{+\infty} xf(x)dx = \int_0^1 x(\theta+1)x^\theta dx \\ &= \int_0^1 (\theta+1)x^{\theta+1} dx = \frac{\theta+1}{\theta+2} \end{aligned}$$

$$\text{令 } E(X) = A_1, \text{ 即 } \frac{\theta+1}{\theta+2} = \bar{X}$$

$$\text{解之得 } \theta \text{ 的矩估计量为 } \hat{\theta} = \frac{2\bar{X}-1}{1-\bar{X}}$$





**例6.1.4** 设总体  $X$  在  $[a, b]$  上服从均匀分布, 其中  $a$ ,  $b$  未知,  $(X_1, X_2, \dots, X_n)$  是来自总体  $X$  的样本, 求  $a$ ,  $b$  的矩估计量.

**解** 因为  $\mu_1 = E(X) = \frac{a+b}{2}$ ,

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4},$$

令

$$\begin{cases} \frac{a+b}{2} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} = A_1 \\ \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4} = \frac{1}{n} \sum_{i=1}^n X_i^2 = A_2 \end{cases}$$



$$\text{即} \begin{cases} a + b = 2A_1, \\ b - a = \sqrt{12(A_2 - A_1^2)}. \end{cases}$$

解方程组得到 $a, b$ 的矩估计量分别为

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$



**例6.1.5** 设总体  $X$  的均值  $\mu$  和方差  $\sigma^2$  都存在, 且有  $\sigma^2 > 0$ , 但  $\mu$  和  $\sigma^2$  均为未知, 又设  $X_1, X_2, \dots, X_n$  是一个样本, 求  $\mu$  和  $\sigma^2$  的矩估计量.

**解**  $E(X) = \mu,$

$$E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$

$$\text{令} \begin{cases} \mu = A_1, \\ \sigma^2 + \mu^2 = A_2. \end{cases}$$

解方程组得到矩估计量分别为  $\hat{\mu} = A_1 = \bar{X},$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$





上例表明:

不管总体服从什么类型的分布,

用样本均值  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  作为总体均值的矩估计,

用样本二阶中心矩  $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  作为总体方差的矩估计.



## § 6.2 极大似然估计

极大似然估计（**Maximum Likelihood Estimation, MLE**），也称为最大概似估计或最大似然估计，是求估计的另一种方法，1821年首先由德国数学家**高斯**（C. F. Gauss）提出，但是这个方法通常被归功于英国的统计学家**罗纳德·费希尔**（R. A. Fisher）。



# 一、极大似然估计法

## 极大似然思想：

**引例** 在一盒中放有红球和白球，且已知两种颜色的球的比例为1:9，但不知何种球多，一人从盒中有放回地随机抽取3个球，发现都为红球，试推断盒中红球多，还是白球多？

分析：引进随机变量 $X = \begin{cases} 1, & \text{取得的球为红球} \\ 0, & \text{否则} \end{cases}$

则 $X$ 就看作一个总体，显然它服从0-1分布，它有一个未知参数 $p$ ， $p$ 只能取0.1或0.9





现在我们进行了抽样, 得到一个容量为3的子样:  
1,1,1. 那么这个样本值出现的概率是

$$P(X_1 = 1, X_2 = 1, X_3 = 1) = p^3$$

当 $p=0.1$ 时其值为0.001, 而当 $p=0.9$ 时其值为0.729.

显然此时我们认为 $p=0.9$ 更合理.

**极大似然原理:** 一个E如有若干个可能结果A, B, C, ..., 在一次试验中, 结果A出现, 则一般认为试验条件对A出现有利, 即A出现的概率很大.



## 似然函数的定义

(1) 设总体  $X$  是离散型随机变量,

设分布律  $P\{X = x\} = p(x; \theta)$ ,  $\theta$  为待估参数,  $\theta \in \Theta$ ,

(其中  $\Theta$  是  $\theta$  可能的取值范围)

$X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本,



又设  $x_1, x_2, \dots, x_n$  为样本  $X_1, X_2, \dots, X_n$  的一个样本值.  
则样本  $X_1, X_2, \dots, X_n$  取到观察值  $x_1, x_2, \dots, x_n$  的概率,  
即事件  $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$  发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta)$$

$$= P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n p(x_i; \theta), \quad \theta \in \Theta,$$

$L(\theta)$  称为样本似然函数.

**注意:** 在似然函数  $L(x_1, x_2, \dots, x_n; \theta)$  中,  $x_1, x_2, \dots, x_n$  是已知样本观测值, 视作已知常数, 未知变量只有  $\theta$ .





(2) 设总体  $X$  是连续型随机变量,

设概率密度为  $f(x; \theta)$ ,  $\theta$  为待估参数,  $\theta \in \Theta$ ,

(其中  $\Theta$  是  $\theta$  可能的取值范围)

$X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本,

则  $X_1, X_2, \dots, X_n$  的联合密度为  $\prod_{i=1}^n f(x_i; \theta)$ .

又设  $x_1, x_2, \dots, x_n$  为相应于样本  $X_1, X_2, \dots, X_n$  的一个样本值.

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$



得到样本值  $x_1, x_2, \dots, x_n$  时, 选取使似然函数  $L(\theta)$

取得最大值的  $\hat{\theta}$  作为未知参数  $\theta$  的估计值,

$$\text{即 } L(x_1, x_2, \dots, x_n; \hat{\theta}) = \sup_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta).$$

(其中  $\Theta$  是  $\theta$  可能的取值范围)

这样得到的  $\hat{\theta}$  与样本值  $x_1, x_2, \dots, x_n$  有关, 记为

$\hat{\theta}(x_1, x_2, \dots, x_n)$ , 参数  $\theta$  的最大似然估计值,

(Maximum Likelihood Estimate)

$\hat{\theta}(X_1, X_2, \dots, X_n)$  参数  $\theta$  的最大似然估计量.

(Maximum Likelihood Estimator)



# 求极大似然估计量的步骤:

## (一) 写出似然函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$

## (二) 取对数

$$\ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta);$$

(三) 对  $\theta$  求导  $\frac{d \ln L(\theta)}{d \theta}$ , 并令  $\frac{d \ln L(\theta)}{d \theta} = 0$ ,

对数似然  
方程

解方程即得未知参数  $\theta$  的最大似然估计值  $\hat{\theta}$ .





最大似然估计法也适用于分布中含有多个未知参数的情况. 此时只需令

$$\frac{\partial}{\partial \theta_i} \ln L = 0, \quad i = 1, 2, \dots, k. \quad \text{对数似然方程组}$$

解出由  $k$  个方程组成的方程组, 即可得各未知参数  $\theta_i$  ( $i = 1, 2, \dots, k$ ) 的最大似然估计值  $\hat{\theta}_i$ .



**例6.2.2** 设  $X \sim B(1, p)$ ,  $X_1, X_2, \dots, X_n$  是来自  $X$  的一个样本, 求  $p$  ( $0 < p < 1$ ) 的最大似然估计量.

**解** 设  $x_1, x_2, \dots, x_n$  为相应于样本  $X_1, X_2, \dots, X_n$  的一个样本值,

$X$  的分布律为  $P\{X = x\} = p^x (1-p)^{1-x}$ ,  $x = 0, 1$ ,

$$\begin{aligned} \text{似然函数 } L(p) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\ &= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}, \end{aligned}$$



$$\ln L(p) = \left( \sum_{i=1}^n x_i \right) \ln p + \left( n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

$$\text{令 } \frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0, \text{ 得 } p = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

由  $\frac{d^2}{dp^2} \ln L(p) < 0$  知  $p$  的最大似然估计值为

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$$

$p$  的最大似然估计量为  $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$

这一估计量与矩估计量是相同的。





### 例6.1.3(续)

$$r.v. X \sim f(x) = \begin{cases} (\theta+1)x^\theta & 0 < x < 1 \\ 0 & \text{其它} \end{cases}, \text{ 其中 } \theta > -1 \text{ 未知,}$$

求  $\theta$  的极大似然估计。

**解** 似然函数 
$$L(\theta) = \prod_{i=1}^n (\theta+1)x_i^\theta = (\theta+1)^n \left( \prod_{i=1}^n x_i \right)^\theta$$

$$\ln L(\theta) = n \ln(1+\theta) + \theta \sum_{i=1}^n \ln x_i$$

$$\text{令 } \frac{d}{d\theta} \ln L(\theta) = \frac{n}{1+\theta} + \sum_{i=1}^n \ln x_i = 0,$$

解之得  $\theta$  的极大似然估计为 
$$\hat{\theta} = -\frac{n}{\sum_{i=1}^n \ln x_i} - 1$$



**练习** 设  $X$  服从参数为  $\lambda$  ( $\lambda > 0$ ) 的泊松分布,  $X_1, X_2, \dots, X_n$  是来自  $X$  的一个样本, 求  $\lambda$  的最大似然估计量.

**解** 因为  $X$  的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda} \quad (x = 0, 1, 2, \dots, n, \dots)$$

所以  $\lambda$  的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left( \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)},$$



$$\ln L(\lambda) = -n\lambda + \left( \sum_{i=1}^n x_i \right) \ln \lambda - \ln \prod_{i=1}^n (x_i!),$$

$$\text{令 } \frac{d}{d\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n (x_i)}{\lambda} = 0,$$

$$\text{解得 } \lambda \text{ 的最大似然估计值 } \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\lambda \text{ 的最大似然估计量为 } \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

**这一估计量与矩估计量是相同的。**





**例6.2.3** 设总体  $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$  为未知参数,

$x_1, x_2, \dots, x_n$  是来自  $X$  的一个样本值, 求  $\mu$  和  $\sigma^2$  的最大似然估计量.

**解**  $X$  的概率密度为  $f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$

$X$  的似然函数为

$$\begin{aligned} L(\mu, \sigma^2) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \\ &= (2\pi)^{-\frac{n}{2}} (\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \end{aligned}$$



$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

$$\text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0, \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0, \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[ \sum_{i=1}^n x_i - n\mu \right] = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases}$$



$$\text{由 } \frac{1}{\sigma^2} \left[ \sum_{i=1}^n x_i - n\mu \right] = 0 \text{ 解得 } \hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\text{由 } -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 \text{ 解得}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

故  $\mu$  和  $\sigma^2$  的最大似然估计量分别为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad \text{它们与相应的矩估计量相同.}$$





$$L(x_1, x_2, \cdots, x_n; \hat{\theta}) = \sup_{\theta \in \Theta} L(x_1, x_2, \cdots, x_n; \theta).$$

**例6.2.4** 设总体  $X$  在  $[a, b]$  上服从均匀分布, 其中  $a, b$  未知,  $x_1, x_2, \cdots, x_n$  是来自总体  $X$  的一个样本值, 求  $a, b$  的最大似然估计量.

**解**  $X$  的概率密度为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其他.} \end{cases}$$



因为  $a \leq x_1, x_2, \dots, x_n \leq b$  等价于  $a \leq x_{(1)}, x_{(n)} \leq b$ ,  
 作为  $a, b$  的函数的似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, x_{(n)} \leq b, \\ 0, & \text{其他} \end{cases}$$

于是对于满足条件  $a \leq x_{(1)}, b \geq x_{(n)}$  的任意  $a, b$  有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$



即似然函数  $L(a, b)$  在  $a = x_{(1)}$ ,  $b = x_{(n)}$  时  
取到最大值  $(x_{(n)} - x_{(1)})^{-n}$ ,

$a, b$  的最大似然估计值

$$\hat{a} = x_{(1)} = \min_{1 \leq i \leq n} x_i, \quad \hat{b} = x_{(n)} = \max_{1 \leq i \leq n} x_i,$$

$a, b$  的最大似然估计量

$$\hat{a} = \min_{1 \leq i \leq n} X_i, \quad \hat{b} = \max_{1 \leq i \leq n} X_i.$$





设总体  $X$  具有分布律:

$X$	1	2	3
$P$	$\theta^2$	$2\theta(1 - \theta)$	$(1 - \theta)^2$

其中  $0 < \theta < 1$  未知。已知取得了一组样本观测值  $x_1 = 1, x_2 = 2, x_3 = 1$ , 试求  $\theta$  的矩估计值和极大似然估计值。



## 极大似然估计的不变性

设  $\theta$  的函数  $u = u(\theta)$ ,  $\theta \in \Theta$  具有单值反函数  $\theta = \theta(u)$ ,  $u \in U$  又设  $\hat{\theta}$  是  $X$  的概率密度函数  $f(x; \theta)$  ( $f$  形式已知) 中的参数  $\theta$  的最大似然估计, 则  $\hat{u} = u(\hat{\theta})$  是  $u(\theta)$  的最大似然估计.

**证明** 因为  $\hat{\theta}$  是  $\theta$  的最大似然估计值, 所以

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \sup_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta),$$

其中  $x_1, x_2, \dots, x_n$  是来自总体  $X$  的一个样本值,



由于

$$\hat{u} = u(\hat{\theta}), \quad \hat{\theta} = \theta(\hat{u}),$$

故

$$L(x_1, x_2, \dots, x_n; \theta(\hat{u})) = \sup_{u \in U} L(x_1, x_2, \dots, x_n; \theta(u)),$$

于是  $\hat{u} = u(\hat{\theta})$  是  $u(\theta)$  的最大似然估计.

此性质可以推广到总体分布中含有多个未知参数的情况.





在例6.2.3中,  $\sigma^2$  的最大似然估计值为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2,$$

函数  $u = u(\sigma^2) = \sqrt{\sigma^2}$  有单值反函数

$$\sigma^2 = u^2 \quad (u \geq 0),$$

故标准差  $\sigma$  的最大似然估计量为

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$



## 例6.2.5

设母体 $\xi \sim \pi(\lambda)$ ,  $\lambda > 0$ 未知.  $\xi_1, \xi_2, \dots, \xi_n$ 是来自 $\xi$ 的子样, 试求 $\theta_1 = e^\lambda$ 和 $\theta_2 = 1/\lambda$ 的极大似然估计量.



注意到 $y = e^x$ 在 $x > 0$ 上单调递增, 因而有唯一的反函数. 从而 $\theta_1 = e^\lambda$ 的极大似然估计量为

$$\hat{\theta}_1 = e^{\hat{\lambda}} = e^{\bar{\xi}}.$$

注意到 $y = 1/x$ 在 $x > 0$ 上单调递减, 因而有唯一的反函数.  $\theta_2 = 1/\lambda$ 的极大似然估计量为

$$\hat{\theta}_2 = \frac{1}{\hat{\lambda}} = \frac{1}{\bar{\xi}}.$$





### 三、估计量的评价标准

从之前的例子可以看到, 对于同一个参数, 用不同的估计方法求出的估计量可能不相同, 如例6.1.3(P14)和例6.2.3(P31), 而且, 很明显, 原则上任何统计量都可以作为未知参数的估计量.

#### 问题

- (1) 对于同一个参数究竟采用哪一个估计量好?
- (2) 评价估计量的标准是什么?

下面介绍几个常用标准.



# 1. 相合性

若  $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$  为参数  $\theta$  的估计量,  
若对于任意  $\theta \in \Theta$ , 当  $n \rightarrow \infty$  时,  $\hat{\theta}_n(X_1, X_2, \dots, X_n)$   
依概率收敛于  $\theta$ , 则称  $\hat{\theta}_n$  为  $\theta$  的相合估计量.

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| < \varepsilon\} = 1$$

注：矩估计量具有相合性



$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, \quad k = 1, 2, \dots;$$

由第四章关于依概率收敛的序列的性质知

$$g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k),$$

其中  $g(x_1, x_2, \dots, x_n)$  是有理函数, 且  $g(\mu_1, \mu_2, \dots, \mu_n) \neq \pm\infty$ .





## 例6.2.6

设总体  $X$  服从参数为  $1/\theta$  的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

其中参数  $\theta > 0$ , 又设  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本, 试证  $\bar{X}$  是  $\theta$  的相合估计量, 而  $nZ = n[\min(X_1, X_2, \dots, X_n)]$  不是  $\theta$  的相合估计量.



因  $E(X) = \theta < \infty$ , 由辛钦大数定律知,  $\bar{X}$  是相合估计量.

而  $Z = \min(X_1, X_2, \dots, X_n)$  服从参数为  $\frac{n}{\theta}$  的指数分布,

$$F_{\min}(x; \theta) = \begin{cases} 1 - e^{-\frac{nx}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

对  $\forall \varepsilon > 0$ ,

$$P(nZ - \theta > \varepsilon) = P\left(Z > \frac{\theta + \varepsilon}{n}\right) = e^{-\frac{\theta + \varepsilon}{\theta}} \rightarrow 0, \text{ as } n \rightarrow \infty.$$

故  $nZ$  不是  $\theta$  的相合估计量.



## 定理1

设  $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$  是  $\theta$  的一个估计量,

若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad \lim_{n \rightarrow \infty} Var(\hat{\theta}_n) = 0$$

则  $\hat{\theta}_n$  是  $\theta$  的相合估计。







## 2. 无偏性

若  $X_1, X_2, \dots, X_n$  为总体  $X$  的一个样本,  
 $\theta \in \Theta$  是包含在总体  $X$  的分布中的待估参数,  
( $\Theta$  是  $\theta$  的取值范围)

若估计量  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  的数学期望  
 $E(\hat{\theta})$  存在, 且对于任意  $\theta \in \Theta$  有  $E(\hat{\theta}) = \theta$ , 则称  
 $\hat{\theta}$  是  $\theta$  的无偏估计量.

无偏估计的实际意义: 无系统误差.



设总体 $X$ （不管服从什么分布，只要均值和方差存在）的均值为 $\mu$ ，方差为 $\sigma^2$ ， $X_1, X_2, \dots, X_n$ 是来自总体 $X$ 的样本， $\bar{X}$ ， $S_n^2$ 分别是样本均值和样本方差，则有

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \mu$$

$$E(S_n^2) = \frac{n-1}{n} \sigma^2$$





## 结论

对于均值  $\mu$ , 方差  $\sigma^2 > 0$  都存在的总体, 若  $\mu, \sigma^2$  均为未知, 则

$E(\bar{X}) = \mu$ ,  $\bar{X}$  是  $\mu$  的无偏估计量;

$E(S_n^2) \neq \sigma^2$ ,  $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的有偏估计量;

$E(S_n^{*2}) = \sigma^2$ ,  $S_n^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的无偏估计量;



## 例6. 2. 7

设  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本, 作为总体均值  $\mu$  的估计量有

$$T_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad T_2 = X_1, \quad T_3 = \sum_{i=1}^n a_i X_i$$

其中  $a_i > 0 (i = 1, 2, \dots, n)$ , 且  $\sum_{i=1}^n a_i = 1$

试证  $T_1, T_2, T_3$  都是  $\mu$  的无偏估计量;



解  $E(T_1) = E(\bar{X}) = \mu$        $E(T_2) = E(X_1) = \mu$

$$E(T_3) = E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i) = \mu \left(\sum_{i=1}^n a_i\right) = \mu$$

由上例可知,一个参数可以有不同的无偏估计量.





**例6.2.8** 设  $\hat{\theta}$  是参数  $\theta$  的无偏估计, 且有  $D(\hat{\theta}) > 0$ , 试证  $\tilde{\theta} = (\hat{\theta})^2$  不是  $\theta^2$  的无偏估计.

**例6.2.9** 设总体服从参数为  $\lambda$  的泊松分布,  $X_1, \dots, X_n$  是一简单随机样本,  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, S_n^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ . 试证:  $\frac{1}{2}(\bar{X} + S_n^{*2})$  是  $\lambda$  的无偏估计.



**例6.2.10** 设总体  $X$  在  $[0, \theta]$  上服从均匀分布, 参数  $\theta > 0$ ,  
 $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本, 试证明  $\hat{\theta}_1 = 2\bar{X}$   
 和  $\hat{\theta}_2 = \frac{n+1}{n} \max(X_1, X_2, \dots, X_n)$  都是  $\theta$  的无偏估计.

**证** 因为  $E(2\bar{X}) = 2E(\bar{X}) = 2E(X) = 2 \times \frac{\theta}{2} = \theta$ ,  
 所以  $\hat{\theta}_1 = 2\bar{X}$  是  $\theta$  的无偏估计量.

因  $X_{(n)} = \max(X_1, X_2, \dots, X_n)$  的概率密度

$$f(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 \leq x \leq \theta, \\ 0, & \text{其他} \end{cases}$$



所以 
$$E(X_{(n)}) = \int_0^{\theta} x \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{n+1}\theta,$$

故有 
$$E\left(\frac{n+1}{n}X_{(n)}\right) = \theta,$$

故  $\hat{\theta}_2 = \frac{n+1}{n}\max(X_1, X_2, \dots, X_n)$  也是  $\theta$  的无偏估计量.





## 例6.2.6 (续)

设总体  $X$  服从参数为  $1/\theta$  的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

其中参数  $\theta > 0$ , 又设  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本, 试证  $\bar{X}$  和  $nZ = n[\min(X_1, X_2, \dots, X_n)]$  都是  $\theta$  的无偏估计.

**证明** 因为  $E(\bar{X}) = E(X) = \theta$ ,

所以  $\bar{X}$  是  $\theta$  的无偏估计量.



而  $Z = \min(X_1, X_2, \dots, X_n)$  服从参数为  $\frac{n}{\theta}$  的指数分布,

$$\text{概率密度 } f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

$$\text{故知 } E(Z) = \frac{\theta}{n}, \quad E(nZ) = \theta,$$

所以  $nZ$  也是  $\theta$  的无偏估计量.



### 3. 有效性

比较参数 $\theta$ 的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ ,如果在样本容量 $n$ 相同的情况下, $\hat{\theta}_1$ 的观察值在真值 $\theta$ 的附近较 $\hat{\theta}_2$ 更密集,则认为 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 与 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 $\theta$ 的无偏估计量,若有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$ ,则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.





## 例6. 2. 7 (续)

设总体 $X$ 的方差 $D(X)$ 存在, 试问 $T_1, T_2, T_3$ 哪个更有效?

$$D(T_1) = D(\bar{X}) = \frac{1}{n} D(X) = \frac{\sigma^2}{n} \quad D(T_2) = D(X_1) = \sigma^2$$

$$D(T_3) = D\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 D(X_i) = \sigma^2 \left(\sum_{i=1}^n a_i^2\right)$$

注意  $\sum_{i=1}^n a_i^2 \geq \frac{1}{n}$

$$\left(\sum_{i=1}^n x_i y_i\right)^2 \leq \left(\sum_{i=1}^n x_i^2\right) \left(\sum_{i=1}^n y_i^2\right).$$

所以 $T_1 = \bar{X}$ 是三个无偏估计量中最有效的估计量



## 例6.2.10 (续)

设总体  $X$  在  $[0, \theta]$  上服从均匀分布, 参数  $\theta > 0$ ,  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本, 试证明  $\hat{\theta}_1 = 2\bar{X}$  和  $\hat{\theta}_2 = \frac{n+1}{n} \max(X_1, X_2, \dots, X_n)$  都是  $\theta$  的无偏估计.

现证当  $n \geq 2$  时,  $\hat{\theta}_2$  较  $\hat{\theta}_1$  有效.

**证明** 由于  $D(\hat{\theta}_1) = D(2\bar{X}) = 4D(\bar{X}) = \frac{4}{n} D(X) = \frac{\theta^2}{3n}$ ,

$$D(\hat{\theta}_2) = D\left(\frac{n+1}{n} X_{(n)}\right) = \left(\frac{n+1}{n}\right)^2 D(X_{(n)}),$$



又因为  $E(X_{(n)}) = \frac{n}{n+1}\theta,$

$$E(X_{(n)}^2) = \int_0^\theta \frac{n}{\theta^n} x^{n+1} dx = \frac{n}{n+2}\theta^2,$$

$$\begin{aligned} D(X_{(n)}) &= E(X_{(n)}^2) - [E(X_{(n)})]^2 \\ &= \frac{n}{n+2}\theta^2 - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n}{(n+1)^2(n+2)}\theta^2, \end{aligned}$$

$$\text{故 } D(\hat{\theta}_2) = \left(\frac{n+1}{n}\right)^2 D(X_{(n)}) = \frac{1}{n(n+2)}\theta^2 < D(\hat{\theta}_1) = \frac{\theta^2}{3n},$$

当  $n \geq 2$ , 所以  $D(\hat{\theta}_2) < D(\hat{\theta}_1)$ ,  $\hat{\theta}_2$  较  $\hat{\theta}_1$  有效.





## 例6.2.6 (续2)

设总体  $X$  服从参数为  $1/\theta$  的指数分布, 概率密度

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

其中参数  $\theta > 0$ , 又设  $X_1, X_2, \dots, X_n$  是来自总体  $X$  的样本.

试证当  $n > 1$  时,  $\theta$  的无偏估计量  $\bar{X}$  较  $nZ$  有效.



**证明** 由于  $D(X) = \theta^2$ , 故有  $D(\bar{X}) = \frac{\theta^2}{n}$ ,

而  $Z = \min(X_1, X_2, \dots, X_n)$  服从参数为  $\frac{n}{\theta}$  的指数分布,

$$\text{概率密度 } f_{\min}(x; \theta) = \begin{cases} \frac{n}{\theta} e^{-\frac{nx}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

又因为  $D(Z) = \frac{\theta^2}{n^2}$ , 故有  $D(nZ) = \theta^2$ ,

当  $n > 1$  时,  $D(nZ) > D(\bar{X})$ ,

故  $\theta$  的无偏估计量  $\bar{X}$  较  $nZ$  有效.



## 定理

**极大似然估计的渐近正态性** 设随机变量 $\xi$  具有密度函数 $f(x; \theta)$ , 未知参数 $\theta \in \Theta$ , 这里 $\Theta$  是一个非退化的开区间, 并假定

(1) 对任何一个 $\theta \in \Theta$  和任一数 $x$ , 偏导数 $\frac{\partial \ln f}{\partial \theta}$ ,  $\frac{\partial^2 \ln f}{\partial \theta^2}$ ,  $\frac{\partial^3 \ln f}{\partial \theta^3}$  存在;

(2) 对 $\Theta$  中每一个 $\theta$ , 不等式

$$\left| \frac{\partial f}{\partial \theta} \right| < F_1(x), \quad \left| \frac{\partial^2 f}{\partial \theta^2} \right| < F_2(x), \quad \left| \frac{\partial^3 f}{\partial \theta^3} \right| < F_3(x)$$

成立, 其中函数 $F_1(x)$  与 $F_2(x)$  在整个数轴 $(-\infty, +\infty)$  上可积,



而函数  $F_3(x)$  满足不等式

$$\int_{-\infty}^{+\infty} F_3(x) f(x; \theta) dx < M$$

其中  $M$  与  $\theta$  无关;

(3) 对  $\Theta$  中每一个  $\theta$  有,

$$0 < E \left( \frac{\partial \ln f}{\partial \theta} \right)^2 = \int_{-\infty}^{+\infty} \left( \frac{\partial \ln f}{\partial \theta} \right)^2 f(x; \theta) dx < +\infty$$



于是若分布参数 $\theta$  的未知真值 $\theta$  是 $\Theta$  的一个内点,则方程

$$\frac{\partial \ln L}{\partial \theta} = 0$$

有一个解 $\hat{\theta}_n = \hat{\theta}(\xi_1, \xi_2, \dots, \xi_n)$  存在, 当 $n \rightarrow \infty$  时,

$$\hat{\theta}(\xi_1, \xi_2, \dots, \xi_n) \xrightarrow{P} \theta,$$

且 $\hat{\theta}_n$  渐近地服从正态分布

$$\hat{\theta}_n \sim AN \left( \theta, \left[ nE \left( \frac{\partial \ln f}{\partial \theta} \right)^2 \right]^{-1} \right).$$

作业:

6.2, 6.5, 6.7

6.8, 6.21, 6.28, 6.33, 6.34, 6.37

6.8, 6.21, 6.27, 6.32, 6.33, 6.36 (新版)

