

§ 7.4 非参数假设检验 (分布的假设检验)



1964年我国某研究所对一批数据提出问题：“苏联的轴承寿命服从对数正态分布，美国的轴承寿命服从威布尔分布，我国的轴承寿命服从什么分布？”

经过多年研究，最后确定我国的轴承寿命服从两参数威布尔分布。随后也选定了估计其中两个参数的估计方法——最好线性无偏估计(BLUE)。

这类问题在国内外经常出现，又如一种新的电子元件设计和制造出来了，它的平均寿命的0.95单侧置信下限是多少？这对其销售量影响很大，因此就先要确定该元件的寿命分布。



分布的检验问题一般只给出原假设，因为它所涉及的备择假设很多，不可能全部列出，也说不清楚。如原假设为正态分布，那么一切非正态分布都可以作为备择假设。



一、正态性检验

二、 χ^2 拟合优度检验

三、科尔莫戈罗夫(Kolmogorov)拟合检验

四、科尔莫戈罗夫-斯米尔诺夫 两子样检验 (K-S检验)



一、正态性检验

一个样本是否来自正态分布的检验称为正态性检验。在这种检验中“样本来自正态分布”是作为原假设而设立的，在 H_0 为真时，人们根据正态分布特性构造一个统计量或一种特定方法，观察其是否偏离正态性。若偏离到一定程度就拒绝原假设，否则就接受原假设。



➤ 正态概率图

根据正态分布性质构造一张图，样本在其上明显不在一条直线上，就认为该样本偏离正态性，从而拒绝正态性假设。

➤ 夏皮洛-威尔克(Shapiro-Wilk)检验($8 \leq n \leq 50$)

➤ 爱泼斯-普利(Epps Pully)检验($n \geq 8$)

正态概率图是一个简单、快速检验正态性的方法，值得首先使用。后两个检验方法对各种非正态分布偏离正态性较为有效，已被国际标准化组织(ISO)认可，形成国际标准ISO 5479 - 1997，我国也采用这两种方法，形成国家标准GB/T4882 - 2001，推广使用。



二、 χ^2 拟合检验法

χ^2 拟合优度检验是著名英国统计学家老皮尔逊(K. Pearson, 1857 - 1936年)于1900年结合检验分类数据的需要而提出的，然后又用于分布的拟合检验与列联表的独立性检验上去。



1、总体可分为有限类，其分布不含未知参数

$H_0: X \sim F(x) = F_0(x).$ (分布的检验问题一般只给出原假设)

基本思想:

将总体 X 的值域分成 k 个互不相容的区间 $A_1 = (a_0, a_1], A_2 = (a_1, a_2], \dots, A_k = (a_{k-1}, a_k]$,

H_0 成立时, $p_i = P(A_i) = P(a_{i-1} < X \leq a_i) = F_0(a_i) - F_0(a_{i-1}),$

设 n 个样本观测值落入区间 A_i 中的频数为 n_i .

则事件 A_i 出现的频率为 $\frac{n_i}{n}$.

$$p_i \leftrightarrow \frac{n_i}{n}$$



浙大

在 n 次试验中, 事件 A_i 出现的频率 $\frac{n_i}{n}$ 与 p_i 往往有差异, 但一般来说, 若 H_0 为真, 且试验次数又多时, 这种差异不应很大.

Pearson χ^2 - 统计量

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

$$\sim \chi^2(k-1) (n \rightarrow \infty) \quad (\text{Th7.1})$$

$k=2$ 时怎么证明?

$$P(\chi^2 \geq \chi^2_{1-\alpha}(k-1)) = \alpha$$

np_i — 理论频数
 n_i — 频数



Pearson χ^2 - 统计量 $\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} \sim \chi^2(k-1)(n \rightarrow \infty) \quad (Th7.1)$

检验步骤:

(1)根据题意给出 $H_0: X$ 服从某一分布;

(2)选取Pearson χ^2 检验统计量;

(3)在给定 α 下,查表得 $\chi_{1-\alpha}^2(k-1)$,即 $P(\chi^2 \geq \chi_{1-\alpha}^2(k-1)) = \alpha$

(4)在观测值 (x_1, x_2, \dots, x_n) 下计算出 χ_0^2 ,

若 $\chi_0^2 \geq \chi_{1-\alpha}^2(k-1)$,则拒绝 H_0 ,否则接受 H_0



注意 在使用 χ^2 检验法时, n 要足够大, np_i 不太小.
根据实践,一般 $n \geq 50$, 每一个 $np_i \geq 5$.

χ^2 拟合检验法一般要求 $np_i \geq 5$ (只有两个分类),
或者至少有80%的 $np_i \geq 5$ (有两个以上的分类).



例1 把一颗骰子重复抛掷 300 次, 结果如下:

出现的点数	1	2	3	4	5	6
出现的频数	40	70	48	60	52	30

试检验这颗骰子的六个面是否匀称? (取 $\alpha = 0.05$)

解 根据题意需要检验假设

H_0 : 这颗骰子的六个面是匀称的.

(或 $H_0 : P\{X = i\} = \frac{1}{6} \quad (i = 1, 2, \dots, 6)$)

其中 X 表示抛掷这骰子一次所出现的点数 (可能值只有 6 个),



取 $A_i = \{X = i\}$ ($i = 1, 2, \dots, 6$)

在 H_0 为真的前提下, $p_i = P(A_i) = \frac{1}{6}$, ($i = 1, 2, \dots, 6$)

$$\begin{aligned}\chi^2 &= \sum_{i=1}^6 \frac{(n_i - np_i)^2}{np_i} \\ &= \frac{(40 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}} + \frac{(70 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}} + \frac{(48 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}} + \\ &\quad \frac{(60 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}} + \frac{(52 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}} + \frac{(30 - 300 \times \frac{1}{6})^2}{300 \times \frac{1}{6}},\end{aligned}$$



$\chi^2 = 20.16$, 自由度为 $6 - 1 = 5$,

查表得 $\chi^2_{1-0.05}(5) = 11.071$, $\chi^2 = 20.16 > 11.071$,

所以拒绝 H_0 ,

认为这颗骰子的六个面不是匀称的.



例2:

一位大学教育专家想知道,对于小型私立大学的四个年级,各年级学生数是否相等?为此,从某校随机抽取4500个本科生,一年级1200人,二年级1100人,三年级1150人,四年级1050人, $\alpha = 0.05$. 试利用这些资料做出 χ^2 拟合检验.



要检验假设 H_0 : 各年级人数相等

年级	频数 n_i	p_i	np_i	$\frac{(n_i - np_i)^2}{np_i}$
一	1200	0.25	1125	5
二	1100	0.25	1125	0.56
三	1150	0.25	1125	0.56
四	1050	0.25	1125	5
合计	4500	1.00	4500	11.12

查表知 $\chi^2_{1-0.05}(4-1) = 7.815 < 11.12$, 故不能认为各年级人数相等.



例3 下表列出了某一地区在夏季的一个月中由100个气象站报告的雷暴雨的次数.

i	0	1	2	3	4	5	≥ 6
n_i	22	37	20	13	6	2	0

其中 n_i 是报告雷暴雨次数为 i 的气象站数. 试用 χ^2 拟合检验法检验雷暴雨的次数 X 是否服从均值 $\lambda = 1$ 的泊松分布(取显著性水平 $\alpha = 0.05$).



解 按题意需检验假设

$$H_0: P\{X = i\} = \frac{\lambda^i e^{-\lambda}}{i!} = \frac{e^{-1}}{i!}, \quad i = 0, 1, \dots$$

在 H_0 下 X 所有可能取的值为 $\Omega = \{0, 1, 2, \dots\}$, 将 Ω 分成如表所示的两两不相交的子集 A_0, A_1, \dots, A_6 , 则有 $P\{X = i\}$ 为

$$p_i = P\{X = i\} = \frac{e^{-1}}{i!}, \quad i = 0, 1, \dots, 5.$$

例如 $p_0 = P\{X = 0\} = e^{-1} = 0.36788$



$$p_3 = P\{X = 3\} = \frac{e^{-1}}{3!} = 0.06131$$

$$p_6 = P\{X \geq 6\} = 1 - \sum_{i=0}^5 p_i = 0.059$$

A_i	n_i	p_i	np_i	$n_i^2 / (np_i)$
$A_0: \{X = 0\}$	22	e^{-1}	36.788	13.16
$A_1: \{X = 1\}$	37	e^{-1}	36.788	37.21
$A_2: \{X = 2\}$	20	$e^{-1}/2$	18.394	21.75
$A_3: \{X = 3\}$	13	$e^{-1}/6$	6.131	33.7
$A_4: \{X = 4\}$	6	$e^{-1}/24$	1.533	
$A_5: \{X = 5\}$	2	$e^{-1}/120$	0.307	
$A_6: \{X \geq 6\}$	0	$1 - \sum_{i=0}^5 p_i$	0.059	

还不够大!



A_i	n_i	p_i	np_i	$n_i^2 / (np_i)$
$A_0: \{X = 0\}$	22	e^{-1}	36.788	13.16
$A_1: \{X = 1\}$	37	e^{-1}	36.788	37.21
$A_2: \{X = 2\}$	20	$e^{-1}/2$	18.394	21.75
$A_3: \{X = 3\}$	13	$e^{-1}/6$	6.131	54.92
$A_4: \{X = 4\}$	6	$e^{-1}/24$	1.533	
$A_5: \{X = 5\}$	2	$e^{-1}/120$	0.307	
$A_6: \{X \geq 6\}$	0	$1 - \sum_{i=0}^5 p_i$	0.059	

要重新计算

127.04

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n$$



计算结果如表所示, 其中有些 $np_i < 5$ 的组予以适当合并, 使得每组均有 $np_i \geq 5$, 如表中第4列花括号所示, 并组后 $k = 4$,

χ^2 的自由度为 $k - 1 = 4 - 1 = 3$

$$\chi_{0.95}^2(k-1) = \chi_{0.95}^2(3) = 7.815$$

现在

$$\chi^2 = 27.04 > 7.815$$

故在显著性水平 0.05 下拒绝 H_0 , 认为样本不是来自均值 $\lambda = 1$ 的泊松分布.



2、总体可分为有限类，但其分布含未知参数

$$H_0 : X \sim F(x) = F_0(x).$$

设总体 X 的真实分布函数为 $F_0(x; \theta_1, \dots, \theta_m)$,
其中 $\theta_1, \dots, \theta_m$ 为 m 个未知参数.

用 $\theta_1, \dots, \theta_m$ 的极大似然估计 $\hat{\theta}_{1L}, \dots, \hat{\theta}_{mL}$ 代替 $\theta_1, \dots, \theta_m$,

取 $A_1 = (a_0, a_1], A_2 = (a_1, a_2], \dots, A_k = (a_{k-1}, a_k]$,

记样本观测值落入 A_i 中的频数为 n_i , 总体 X 落入 A_i 中的概率用 \hat{p}_i 代替,

$$\hat{p}_i = F_0(a_i; \hat{\theta}_{1L}, \dots, \hat{\theta}_{mL}) - F_0(a_{i-1}; \hat{\theta}_{1L}, \dots, \hat{\theta}_{mL}).$$

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i} \sim \chi^2(k - m - 1)(n \rightarrow \infty) \quad (Th7.2)$$



例4:

下表是上海1875年到1955年的81年间, 根据其中的63 年观察记录到的一年中(5月到9月)下暴雨次数的整理资料:

一年中暴雨次数 i	0	1	2	3	4	5	6	7	8	≥ 9
实际年数 n_i	4	8	14	19	10	4	2	1	1	0

试检验一年中下暴雨的次数 X 是否服从 $Possion$ 分布. $(\alpha = 0.05)$



$H_0: \xi \sim P(\lambda)$, 极大似然估计得 $\hat{\lambda}_L = \bar{\xi} = 2.86$.

$$\hat{p}_1 = \frac{2.86^0}{0!} e^{-2.86}, \hat{p}_2 = \frac{2.86^1}{1!} e^{-2.86}, \dots$$

区间	频数 n_i	$\hat{p}_i = F_0(a_i) - F_0(a_{i-1})$	$n\hat{p}_i$	$(n_i - n\hat{p}_i)^2$	$(n_i - n\hat{p}_i)^2 / n\hat{p}_i$
[0,0]	4	0.057	3.591	0.167	0.0465
(0,1]	8	0.164	10.332	5.438	0.526
(1,2]	14	0.234	14.742	0.551	0.037
(2,3]	19	0.230	14.49	20.34	1.404
(3,4]	10	0.164	10.332	0.110	0.011
(4,5]	4	0.094	5.922	3.694	0.624
(5,6]	2	0.045	2.835	0.697	0.246
(6,7]	1	0.010	0.63	0.1369	0.217
(7, ∞)	1	0.002	0.126	0.764	6.06
合计	63	1	63		9.1715

查表知 $\chi_{1-0.05}^2(9-1-1) = 14.067 > 9.1715$, 故可以认为服从 *Poisson* 分布.



区间	频数 n_i	$\hat{p}_i = F_0(a_i) - F_0(a_{i-1})$	$n\hat{p}_i$	$(n_i - n\hat{p}_i)^2$	$(n_i - n\hat{p}_i)^2 / n\hat{p}_i$
[0,1]	12	0.221	13.923	3.6979	0.2656
(1,2]	14	0.234	14.742	0.551	0.037
(2,3]	19	0.230	14.49	20.34	1.404
(3,4]	10	0.164	10.332	0.110	0.011
(4, ∞)	8	0.151	9.513	2.289	0.241
合计	63	1	63		1.9466

查表知 $\chi^2_{1-0.05}(5-1-1) = 7.815 > 1.9466$, 故可以认为服从 *Poisson* 分布.



例5:(p352)

研究混凝土抗压强度的分布.200件混凝土制件的抗压强度以分组形式列出.

压强区间 kg/cm^2	频数 n_i	组中值
190 ~ 200	10	195
200 ~ 210	26	205
210 ~ 220	56	215
220 ~ 230	64	225
230 ~ 240	30	235
240 ~ 250	14	245

试问抗压强度 ξ 是否服从正态分布. $(\alpha = 0.05)$



$H_0: \xi \sim F(x) = F_0(x) = \Phi(x; \mu, \sigma^2)$, 其中 μ, σ^2 为未知参数.

μ 和 σ^2 的极大似然估计为 $\hat{\mu}_L = \bar{x}$ 和 $\hat{\sigma}_L^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$.

设 x_i^* 表示第 i 组区间的中点值, 计算

$$\hat{\mu}_L = \frac{1}{n} \sum_{i=1}^n x_i^* n_i = 221, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i^* - \bar{x})^2 n_i = 152, \quad \hat{\sigma} = 12.33.$$

在正态分布 $N(221, 12.33^2)$ 的分布下, 计算每个区间理论概论值的估计:

$$\begin{aligned} \hat{p}_i &= P(a_{i-1} < \xi \leq a_i) = P\left(\frac{a_{i-1} - 221}{12.33} < \frac{\xi - 221}{12.33} \leq \frac{a_i - 221}{12.33}\right) \\ &= \Phi_0\left(\frac{a_i - 221}{12.33}\right) - \Phi_0\left(\frac{a_{i-1} - 221}{12.33}\right) =: \Phi_0(u_i) - \Phi_0(u_{i-1}). \end{aligned}$$



区间 ($a_{i-1}, a_i]$	频数	标准化区 间 ($u_{i-1}, u_i]$	$\hat{p}_i = \Phi_0(u_i) - \Phi_0(u_{i-1})$	$n\hat{p}_i$	$(n_i - n\hat{p}_i)^2$	$(n_i - n\hat{p}_i)^2 / n\hat{p}_i$
$(-\infty, 200]$	10	$(-\infty, -1.7]$	0.045	9.0	1.00	0.11
(200, 210]	26	$(-1.7, -0.89]$	0.142	28.4	5.76	0.20
(210, 220]	56	$(-0.89, -0.08]$	0.281	56.2	0.04	0.00
(220, 230]	64	$(-0.08, 0.73]$	0.299	59.8	17.64	0.29
(230, 240]	30	$(0.73, 1.54]$	0.171	34.2	17.64	0.52
$(240, \infty)$	14	$(1.54, \infty)$	0.062	12.4	2.56	0.23
合计	200		1.000	200		1.35

查表知 $\chi^2_{1-0.05}(6-2-1) = 7.815 > 1.35$, 故可以认为服从正态分布。



练习：在股票投资中有一个流行的说法：盈利、持平和亏损的比例为1:2:7。2003年2月8日《上海青年报》第16版上发表了一个调查数据，在1270位被调查的股民中盈利者273人，持平者240人，亏损者757人。这些调查数据能否认可流行的说法？

这个问题归结为检验如下假设的问题：

$$H_0: P(\text{盈})=0.1, P(\text{平})=0.2, P(\text{亏})=0.7$$



股民盈亏数据的 χ^2 检验计算表

i	O_i	p_i	$E_i = np_i$	$ O_i - E_i $	$\frac{(O_i - E_i)^2}{E_i}$
1	273	0.1	127	145	165.55
2	240	0.2	254	14	0.77
3	757	0.7	889	132	19.60
和	1 270	1.0	1 270	/	185.92

$$\chi^2 = 188.21 > \chi^2_{0.95}(2) = 5.99$$



对“拟合优度”作一些说明：

在分布检验中常要问：

(1) 实际数据与理论分布是否符合？

在分布检验中对原假设 H_0 作出“拒绝”或“接受”的判断。

(2) 若符合，符合程度如何？能否提供一个(介于0~1之间的)数字作为符合程度的数量指标？

老皮尔逊研究了这个问题，找到了这个数量指标，并称之为“拟合优度”(goodness of fit)。

拟合优度——分布检验中的p值。



在例5中

$$p = P\{\chi^2 \geq \chi_0\} = P\{\chi^2 \geq 1.35\} = 0.72$$

拟合优度(即 p 值)越大, 表示实际数据与理论分布拟合得越好, 该理论分布就获得更多实际数据支持。而显著性水平 α 只是人们设置的一个门槛, 当拟合优度低于 α 时拒绝 H_0 , 拟合优度越低, 人们放弃 H_0 越放心; 当拟合优度高于 α 时, 接受 H_0 , 若取 $\alpha=0.05$, 当 $p=0.06$ 或 $p=0.90$ 时虽都接受 H_0 , 但后者使数据对理论分布的支持比前者强得多, 前者勉强过关, 后者接近完美。



三、科尔莫戈罗夫(Kolmogorov)拟合检验

克服了卡方检验依赖于区间划分的缺点，但要求**总体分布必须假定为连续**.

定理7.3 (P355) $D_n = \sup_{x \in R} |F_n(x) - F(x)|$

$$P\left(D_n < \lambda + \frac{1}{2n}\right) = \begin{cases} 0, & \lambda < 0 \\ \int_{\frac{1}{2n}-\lambda}^{\frac{1}{2n}+\lambda} \int_{\frac{3}{2n}-\lambda}^{\frac{3}{2n}+\lambda} \cdots \int_{\frac{2n-1}{2n}-\lambda}^{\frac{2n-1}{2n}+\lambda} f(y_1, \cdots, y_n) dy_1 \cdots dy_n, & 0 \leq \lambda < \frac{2n-1}{2n} \\ 1, & \lambda \geq \frac{2n-1}{2n} \end{cases} \quad (7.33)$$

其中

$$f(y_1, \cdots, y_n) = \begin{cases} n!, & 0 < y_1 < \cdots < y_n < 1 \\ 0, & \text{其他} \end{cases}$$



$$\lim_{n \rightarrow \infty} P\{\sqrt{n}D_n \leq \lambda\}$$

$$\rightarrow K(\lambda) = \begin{cases} \sum_{j=-\infty}^{+\infty} (-1)^j \exp(-2j^2 \lambda^2), & \lambda > 0 \\ 0, & \lambda \leq 0 \end{cases}$$



步骤: (P356)

H_0 : X 服从某连续型分布 $F(x)$

经验分布函数:

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ \frac{j-0.5}{n}, & x_{(j)} \leq x < x_{(j+1)}, j = 1, 2, \dots, n-1 \\ 1, & x \geq x_{(n)} \end{cases}$$

$$D_n = \sup_{x \in R} |F_n(x) - F(x)|$$

$$= \max_{1 \leq j \leq n} |F_n(x_{(j)}) - F(x_{(j)})|, |F_n(x_{(j-1)}) - F(x_{(j)})|$$



四、科尔莫戈罗夫-斯米尔诺夫两子样检验（K-S检验）

$$H_0 : F_1(x) = F_2(x)$$

定理7.4 (P361) $D_{n_1, n_2} = \sup_{x \in R} |F_{1n_1}(x) - F_{1n_2}(x)|$

$$\lim_{n_1, n_2 \rightarrow \infty} P\left\{\sqrt{\frac{n_1 n_2}{n_1 + n_2}} D_{n_1, n_2} \leq \lambda\right\}$$

$$\rightarrow K(\lambda) = \begin{cases} \sum_{j=-\infty}^{+\infty} (-1)^j \exp(-2j^2 \lambda^2), & \lambda > 0 \\ 0, & \lambda \leq 0 \end{cases}$$



作业: p378. 7.23, 7.24

